

Análisis de Estrategia Cognitiva en una Tarea Flanker

Luis Luarte

Preámbulo

Los resultados derivados de la tarea flanker han sido considerados como un proceso de múltiples etapas (Eriksen & Eriksen, 1974), que involucra:

Procesamiento automático. Los participantes procesarán las flechas cercanas al objetivo, incluso cuando se les instruya ignorarlas. Por lo tanto, los flaqueadores serán procesados y presumiblemente influirán de alguna manera en el tiempo de reacción.

Competencia de respuesta. Cuando los estímulos flaqueadores no son iguales a los estímulos objetivo, debido al procesamiento automático, la respuesta va a ser influenciada tanto por los flaqueadores como por el objetivo. En la condición donde no hay competencia, no hay forma de desenredar si la competencia está ocurriendo, pero es trivial desde la perspectiva de la respuesta final.

Control inhibitorio y selección. Siguiendo el punto anterior, para producir una respuesta correcta, es necesario algún tipo de proceso inhibitorio.

Preparación. Como los participantes probablemente emplean algún mecanismo relacionado con la memoria, ya sea procedimental o de otro tipo, existe la expectativa de necesitar inhibir los flaqueadores distractores, incluso si el siguiente ensayo no presenta tales distracciones.

Por lo tanto, incluso con información perfecta, un participante debe gastar una cierta cantidad de tiempo en un proceso inhibitorio para generar la respuesta correcta. Sin embargo, el uso de la estrategia inhibitoria no es inmediatamente obvio: (i) un participante podría optar por nunca involucrarse en tal proceso inhibitorio (a costa de una menor precisión), (ii) optar por involucrarse en un proceso inhibitorio constante o (iii) determinar el estado de este dinámicamente usando algún tipo de información derivada de la realización de la tarea. Las estrategias afectarán el resultado en la tasa de respuestas correctas, los tiempos de reacción y la dependencia de ensayos previos.

Dadas estas estrategias generales, podemos construir algunas predicciones. En cuanto a las tasas de error, esperaríamos que la estrategia (i) muestre niveles de error al azar en los ensayos incongruentes (independiente de los ensayos previos), la estrategia (ii) debería mostrar tasas de error mejores que el azar en los ensayos incongruentes (independiente de los ensayos previos), y la estrategia (iii), por otro lado, debería mostrar algún tipo de

dependencia de los ensayos previos, mientras que las predicciones sobre las tasas de error per se no son obvias.

Para los tiempos de reacción, la estrategia (i) debería mostrar tiempos de reacción similares entre ensayos congruentes e incongruentes, la estrategia (ii) tiempos de reacción más lentos en ensayos incongruentes (independiente de los ensayos previos), y la estrategia (iii) debería mostrar una variabilidad en el tiempo de reacción que depende de los ensayos previos. Para construir un marco adecuado, debemos asumir qué tipo de información de los ensayos previos podría usarse para ajustar el control en la estrategia (iii), y qué tipo de información no se correlaciona con los resultados de las estrategias (i) y (ii).

Dada la tarea flanker, tenemos dos fuentes principales de información: el tipo de ensayo previo y los tiempos de respuesta reales. La precisión de los ensayos previos también puede ser considerada. Sin embargo, no tenemos una señal de retroalimentación explícita, lo que dificulta desenredar si el participante consideró su respuesta correcta o no. La pregunta aquí es qué características del tipo de ensayo previo y del tiempo de respuesta podríamos usar, ya que no es obvio si deberíamos considerar solo el ensayo previo o los últimos tres. Para que nuestro marco sea manejable, proponemos el uso de la expectativa del tipo de ensayo y del tiempo de reacción.

La expectativa para el tipo de ensayo asume una media móvil exponencialmente ponderada (EWMA, un proceso de memoria simple con pérdida de memoria), reflejando un modelo muy simple de cómo los participantes modulan el comportamiento basado en experiencias previas, lo que parece recuperar las principales características conductuales en tareas secuenciales (Meyniel et al., 2016):

$$E_t = \alpha \cdot O_t + (1 - \alpha) \cdot E_{t-1}$$

Donde $E(t)$ es la expectativa en el ensayo actual t , $O(t)$ es la observación en el ensayo actual t , $E(t-1)$ es la expectativa del ensayo previo y α es la tasa de aprendizaje. Por lo tanto, estamos asumiendo que los participantes determinan las modificaciones de la estrategia basándose en la memoria, y como α es tratado como un parámetro libre, es el error de predicción de la EWMA el que impulsa la modificación.

Para los tiempos de reacción usamos un enfoque de modelado de dos pasos donde primero determinamos la expectativa del tiempo de reacción usando una regresión lineal simple:

$$RT \sim \text{ÍndiceEnsayo} + \text{TipoEnsayo} + \text{CondiciónITI}$$

El tiempo de reacción (RT) se modela a lo largo de los ensayos, el tipo de ensayo y si la tarea es con intervalos inter-ensayo (ITI) lentos o rápidos. El segundo paso es calcular la desviación de esta expectativa (sorpresa) como un impulsor de la modificación de la

estrategia; para esto, simplemente tomamos el residuo estandarizado del modelo.

$$\frac{\text{Valor}_{\text{actual}} - \text{Valor}_{\text{predicho}}}{\sigma_{\text{residuos}}}$$

Aunque hemos proporcionado un marco predictivo general para las estrategias potenciales, se necesita una definición formal de estas utilizando un enfoque de parámetros generadores más probables. Para esto elegimos el modelo de difusión de deriva (DDM), que asume que una decisión se toma acumulando evidencia ruidosa a lo largo del tiempo hasta que se alcanza un umbral (Ratcliff, 1978). La salida del modelo es una distribución de probabilidad de los tiempos de reacción para las elecciones correctas e incorrectas.

$$\Pr(\text{RT}, \text{Elección}) = F_{\text{DDM}}(\alpha, \delta, \tau, \beta)$$

Donde $\Pr(\text{RT}, \text{Elección})$ es la probabilidad de tomar una elección específica en una cantidad específica de tiempo, F_{DDM} es la función de densidad de probabilidad de Wiener, que está determinada por α (separación de límites), δ (tasa de deriva), τ (tiempo no decisional) y β (sesgo del punto de partida). Luego, mapeamos las estrategias propuestas a los parámetros del modelo.

α bajo reflejando una estrategia más "impulsiva" (menos necesidad de acumulación de evidencia para producir una respuesta), y δ que muestra una diferencia mínima entre ensayos congruentes e incongruentes (debido a la falta de control inhibitorio). α alto reflejando un control inhibitorio constante, y δ significativamente más alto (menos negativo) para ensayos incongruentes, ya que el control inhibitorio está mejorando activamente la calidad de la acumulación de evidencia. Interacción significativa de α y δ con la señal de sorpresa o la desviación de la expectativa (ya sea del tiempo de reacción, del tipo de ensayo o de ambos).

Por lo tanto, la estimación de los parámetros DDM α y δ se toma como combinaciones lineales utilizando la señal de sorpresa.

$$\alpha_t = \beta_0 + \beta_1 \cdot S_{t-1}$$

$$\delta_t = \gamma_0 + \gamma_1 \cdot S_{t-1}$$

Donde S_{t-1} es la señal de sorpresa del ensayo previo, lo que nos permite derivar, en principio, una inferencia causal. Sin embargo, dados los datos, esto conlleva una endogeneidad considerable, ya que los parámetros DDM se estimarán para el experimento completo y no ensayo por ensayo, permitiendo una fuga de información.

La última parte restante de este marco es la inclusión explícita del ITI largo/corto. Asumimos que, debido a que esta es una variable entre tareas, debería afectar la política de estrategia general; un ITI más corto debería seguir una estrategia preestablecida sin

muchas modificaciones, mientras que un ITI más largo debería permitir más modificaciones de la estrategia. La lógica para esto es simple: tener menos tiempo de procesamiento disminuye el potencial para estrategias complejas, mientras que más tiempo de procesamiento permite desarrollar e integrar información de ensayos previos para informar la política de estrategia.

Hipótesis Conductual

El ITI de la tarea modula la variabilidad de la selección de estrategia, un ITI corto mostrará una baja variación de la estrategia, mientras que un ITI largo mostrará una mayor variabilidad (debido a la elección de estrategias basadas en información previa). La selección de estrategia es modulada por la expectativa del tipo de ensayo y la sorpresa del tiempo de reacción; errores de predicción más altos (en tiempos de reacción y expectativa de ensayo) modulan los parámetros δ y α del DDM.

Modelos Computacionales

Primero, examinamos si ocurre algún control inhibitorio, ya que esta es la principal variable de interés entre las tres estrategias propuestas. Para modelar esto, usamos el efecto flanker (diferencias entre ensayos incongruentes y congruentes) como un proxy del control inhibitorio y hacemos las siguientes preguntas: (i) ¿son los tiempos de reacción más lentos en ensayos incongruentes versus congruentes (análisis I) y (ii) son los ensayos incongruentes versus congruentes menos precisos (análisis II).

Análisis I: Efecto Flanker

Para descartar la estrategia (i) esperamos encontrar diferencias estadísticamente significativas tanto en el RT como en la precisión (los scripts tienen secciones que coinciden con los números de análisis del manuscrito). Los modelos lineales mixtos con RT_{log} por tipo de ensayo y condición ITI con pendientes aleatorias por participante mostraron un efecto flanker en ambas condiciones ITI (Rápido/Congruente: 0.46 ± 0.01 seg., Rápido/Incongruente: 0.49 ± 0.01 seg., Lento/Congruente: 0.58 ± 0.01 seg., Lento/Incongruente: 0.68 ± 0.02 seg., Figura 1, 2), con diferencias estadísticamente significativas entre las proporciones (análisis en escala logarítmica) en condiciones congruentes e incongruentes (Proporción Rápida: 0.93 ± 0.007 , $p < 0.01$, Proporción Lenta: 0.86 ± 0.006 , $p < 0.01$). Interesantemente, un análisis de diferencia en diferencias mostró que la diferencia de tiempos de reacción Congruente - Incongruente fue mayor para la condición de ITI lento (diferencia estimada: 0.07 ± 0.01 , $p < 0.01$), mostrando potencialmente más diversidad en las estrategias cognitivas empleadas.

Análisis II: Tasa de Error

Para el análisis de la tasa de error, usamos un modelo mixto generalizado con familia binomial para modelar la probabilidad de respuestas correctas y permitimos un intercepto y pendiente aleatorios (entre congruente e incongruente) por participante, los resultados mostraron una mayor precisión en los ensayos congruentes versus incongruentes en ambas condiciones ITI (odds ratio rápido: 2.94 ± 0.86 , $p < 0.01$, odds ratio lento: 6.95 ± 2.09 , $p < 0.01$, Figura 3), de manera similar al análisis de RT también encontramos que las diferencias en las condiciones de ITI lento fueron mayores (diferencia estimada: -0.86 , $p < 0.01$). Con estos modelos preliminares podemos descartar la estrategia (i) ya que el efecto flanker está presente tanto en el RT como en las tasas de error, además, mostramos las primeras líneas de evidencia de que la condición de ITI rápido reduce la variabilidad entre la selección de estrategia en ensayos congruentes/incongruentes como lo muestra el análisis de diferencia en diferencias.

Análisis III: Información del Ensayo Previo

Con las estrategias (ii) y (iii) en consideración, la variable principal fue cómo la información del ensayo previo actúa como predictor o no para la selección de la estrategia actual (análisis III). La lógica es que si, como estipula la estrategia (ii), hay un control inhibitorio constante, debería haber un RT constante para los ensayos congruentes/incongruentes dentro de las condiciones de ITI lento/rápido, por lo tanto, el RT del ensayo previo no debería tener ninguna capacidad predictiva al controlar por todas las cuatro condiciones posibles. Para determinar esto, ajustamos un modelo lineal mixto con RT_{log} y el tiempo de reacción previo, controlando por el tipo de ensayo, el tipo de ensayo previo y la condición ITI, con intercepto y pendiente aleatorios entre tipos de ensayo por participante, y luego probamos el coeficiente de RT_{previo} contra 0. El RT del ensayo previo en la condición rápida fue diferente de 0 tanto en ensayos congruentes como incongruentes (congruente: 0.32 ± 0.03 , $p < 0.01$, incongruente: 0.42 ± 0.03 , $p < 0.01$, Figura 4), mientras que no se encontró diferencia estadísticamente significativa para la condición lenta (congruente: 0.0003 ± 0.0007 , $p = 0.96$, incongruente: 0.002 ± 0.001 , $p = 0.09$, Figura 4). Esto muestra evidencia a favor del uso de la estrategia (iii), ya que la información del ensayo previo muestra un efecto general en el RT.

Análisis IV: Parámetros DDM

Para las consideraciones iniciales de DDM, los parámetros se ajustaron para cada participante utilizando optimización no lineal con la función de densidad de Wiener para la estimación de máxima verosimilitud (R Core Team, 2025; Wabersich & Vandekerckhove, 2014). La separación de límites (α , Figura 5) no mostró diferencias significativas entre ensayos congruentes e incongruentes en el ITI rápido, y en el ITI lento solo alcanzó una significancia a nivel de tendencia (rápido: 0.09 ± 0.13 , $p = 0.5$, lento: 0.24 ± 0.13 , $p = 0.07$, modelos lineales mixtos con intercepto aleatorio por participante, Figura 5), la tasa de deriva (δ) mostró diferencias significativas en el ITI rápido y lento (rápido: 1.01 ± 0.33 , $p < 0.01$, lento: 1.76 ± 0.33 , $p < 0.01$, Figura 5), el sesgo del punto de partida (β) no mostró diferencias en ninguna condición de ITI (rápido: -0.01 ± 0.03 , $p = 0.67$, lento: 0.02 ± 0.03 , $p = 0.52$), y el tiempo no decisional (τ) mostró diferencias solo en el ITI rápido (rápido: -0.05 ± 0.02 , $p < 0.05$, lento: -0.02 ± 0.02 , $p = 0.25$, Figura 5). Esto añadió más evidencia hacia la estrategia (iii), lo más relevante para nuestro marco es que δ mostró diferencias significativas en ambas condiciones de ITI. Un análisis posterior mostró que la tasa de deriva es mayor en condiciones lentas pero solo para ensayos congruentes (congruente rápido – lento: -0.84 ± 0.33 , $p < 0.05$, incongruente rápido – lento: -0.08 ± 0.33 , $p = 0.79$, Figura 5). Este es un efecto que no fue anticipado por nuestro marco, ya que esperaríamos que esta diferencia existiera para los ensayos incongruentes. Podríamos especular que esto podría deberse a que los ensayos incongruentes son particularmente difíciles para los par-

ticipantes, lo que es consistente con la baja precisión de 70% obtenida en este tipo de ensayos.

Habiendo establecido la presencia de una estrategia inhibitoria dinámica y dependiente del contexto, ahora nos centramos en nuestra hipótesis principal: que la variabilidad ensayo por ensayo de esta estrategia es modulada por el contexto del ITI. Para probar esto, determinamos un modelo comprensivo que permite la estimación simultánea de todos los componentes del modelo, desde la señal de expectativa ensayo por ensayo hasta su influencia en los parámetros finales del DDM. Esto asegura que la incertidumbre se propague adecuadamente a través de todo el sistema, proporcionando una estimación más robusta de cómo la influencia de la historia de los ensayos en la estrategia es contingente al contexto temporal (ITI rápido/lento) de la tarea, al tiempo que proporciona un mecanismo específico de cómo se produce la estrategia inhibitoria.

Análisis V: Mecanismo de Selección de Estrategia Inhibitoria

Primero generamos las características de media móvil exponencial y error de predicción del tiempo de reacción, ajustamos el modelo DDM (ver métodos) y realizamos bootstrap de los coeficientes obtenidos (5000 iteraciones, haciendo bootstrap de los datos completos de los participantes). Nuestros coeficientes de interés fueron la separación de límites x EWMA (BS_EWMA), que representa el efecto de la expectativa del tipo de ensayo sobre el parámetro de separación de límites, que es nuestra política proactiva propuesta que considera la estructura general de la tarea, y la tasa de deriva x error de predicción del tiempo de reacción (DELTA_SURP), que representa el control ascendente de la política de estrategia. El coeficiente BS_EWMA fue significativamente positivo, mostrando una modulación más pronunciada en el ITI rápido (rápido versus lento, $\beta_{\text{bootstrapped}} = 0.06 \pm 0.01$, IC 95% [0.04, 0.09], Figura 6). El coeficiente DELTA_SURP fue significativamente negativo, mostrando una modulación disminuida para el ITI rápido (rápido versus lento, $\beta_{\text{bootstrapped}} = -0.32 \pm 0.03$, IC 95% [-0.39, -0.25], Figura 6). Para determinar la validez de los resultados del modelo propuesto, primero observamos que todos, excepto la interacción de BS_EWMA con el tipo de ensayo, fueron estadísticamente significativos. Luego, realizamos una comparación de modelos (ver métodos) contra un modelo que incluía solo el parámetro DDM sin ninguna especificación adicional; los resultados mostraron que nuestro modelo completo era más probable dado los datos ($\chi^2_{\text{Fisher}} = 3202.64, p < 0.01$, Figura XX). Finalmente, para determinar si el ITI modulaba la variabilidad de la selección de estrategia, realizamos un análisis de error de predicción de nuestro modelo completo sobre las condiciones de ITI rápido y lento (ver métodos, variabilidad de la estrategia). La lógica es que una baja varianza en la selección de estrategia debería correlacionarse con un menor error de predicción del modelo, y una alta varianza en la selección de estrategia con un mayor error de predicción del modelo, ya que el modelo se estimó a través de los

ensayos de forma participante por participante. Los resultados mostraron tasas de error del modelo modestas en general ($\text{RMSE}_{\text{rápido}}=0.15\pm0.009$, $\text{RMSE}_{\text{selecto}}=0.18\pm0.01$), y un mayor error en la condición de ITI rápido ($\text{rápido/lento} = 0.85\pm0.01$, $p < 0.01$).

Discusión

Nuestros resultados apoyan un modelo dinámico y dependiente del contexto de control inhibitorio (Estrategia iii), donde los participantes actualizan continuamente su estrategia basándose en la historia de los eventos de la tarea. Los análisis preliminares confirmaron la presencia de un robusto efecto flanker tanto en los tiempos de reacción como en las tasas de error, permitiéndonos descartar una simple estrategia automática. Más importante aún, estos modelos preliminares revelaron las primeras líneas de evidencia para nuestra hipótesis principal: la diferencia en el rendimiento entre ensayos congruentes e incongruentes fue significativamente mayor en la condición de ITI lento, sugiriendo que el contexto temporal de la tarea modula la aplicación del control cognitivo. El análisis posterior mostró que el RT del ensayo previo era un fuerte predictor solo en la condición de ITI rápido, sugiriendo un cambio entre un modo de procesamiento rítmico y fuertemente acoplado bajo presión de tiempo y un modo más flexible y basado en la vigilancia cuando el tiempo no era una restricción.

El DDM dinámico completo proporciona un mecanismo formal para este cambio estratégico. La comparación de modelos, mostrando un ajuste significativamente mejor para el modelo dinámico completo sobre un modelo base restringido, validó la necesidad de incluir predictores ensayo por ensayo. Nuestra hipótesis conductual central —que el ITI largo permitiría una mayor variabilidad estratégica— fue confirmada por el análisis del error de predicción del modelo; el RMSE significativamente mayor en la condición lenta indica que un único modelo estático es un peor ajuste, consistente con una estrategia que fluctúa más de ensayo a ensayo. Los coeficientes bootstrapped del modelo final revelaron la naturaleza específica de este control dinámico. El efecto de interacción significativo con EWMA muestra que los participantes estaban actualizando sus expectativas basándose en eventos pasados. Esta expectativa aprendida, a su vez, moduló la cautela en la decisión (separación de límites), mientras que las señales de monitoreo del rendimiento (sorpresa de RT) modularon la eficiencia del procesamiento (tasa de deriva), apoyando un sistema de control que utiliza diferentes señales informativas para gestionar distintos aspectos del proceso de decisión.

En conjunto, nuestros hallazgos sugieren un sistema de control cognitivo altamente adaptativo que cambia toda su política operativa basándose en las demandas temporales del entorno. Bajo un ITI corto, el sistema entra en un modo "apresurado" y de alta preparación, caracterizado por una menor calidad de procesamiento (menor tasa de deriva), una menor cautela en la decisión (menor separación de límites) y una mayor sensibilidad a la retroalimentación de rendimiento inmediata. Por el contrario, el ITI largo permite un modo "deliberado", caracterizado por un procesamiento de mayor fidelidad y una aplicación más variable y exploratoria de las estrategias cognitivas, ya que el sistema tiene el tiempo y los recursos para ajustar sus parámetros ensayo por ensayo.

Propuesta de Diseño Experimental a Nivel Neural

Uno de nuestros principales hallazgos a partir de la hipótesis y resultados a nivel conductual es que probablemente existe una variabilidad en la política de estrategia entre el ITI rápido y lento, y queremos desenredar cómo se implementa esto a nivel neural. Proponemos un diseño experimental de dos fases.

Fase I: Métodos

El objetivo de esta primera fase es utilizar resonancia magnética funcional (fMRI) para encontrar qué áreas cerebrales están asociadas con los ajustes estratégicos ensayo por ensayo que mostraron nuestros resultados. Los participantes realizarán las versiones de la tarea flanker con ITI rápido y lento mientras están en un escáner de fMRI. Adquiriremos tanto escaneos estructurales de alta resolución como escaneos funcionales. Con estos datos nos centraremos en los intervalos inter-ensayo (donde proponemos que es probable que ocurra el cambio de política, ya que esta es la principal diferencia entre tareas) y usaremos predictores ensayo por ensayo (mismo modelo que el utilizado para el análisis a nivel conductual con la adición de un coeficiente para la pendiente de los parámetros a lo largo de los ensayos) como regresores en un modelo lineal de los datos de fMRI (señal BOLD en un solo vóxel). Generaremos dos series de tiempo principales a partir de los ajustes del DDM: (i) error de predicción de RT y (ii) error de predicción de EWMA, ya que estas fueron las dos características principales que diferenciaron nuestro modelo completo entre las condiciones de ITI lento/rápido. El modelo lineal para los datos de fMRI incluirá estos dos regresores, modulados paramétricamente en el ITI de cada ensayo. Esto nos permitirá encontrar áreas cerebrales donde la señal BOLD se correlaciona significativamente con estas señales computacionales específicas de sorpresa/error.

Fase I: Hipótesis

Hipotetizamos que el córtex prefrontal dorsolateral (dlPFC, por su probable papel en el control de la estrategia conductual inducido por conflicto (Mansouri et al., 2009)) y el córtex parietal posterior (PPC, debido a su correlación con el parámetro de tasa de deriva del DDM, (Gold & Shadlen, 2007)) mostrarán una mayor actividad que se correlaciona específicamente con estas señales de sorpresa/error solo en la condición de ITI lento, ya que esta es la condición en la que hipotetizamos que los participantes tienen el tiempo y los recursos para usar esta información dinámicamente y ajustar su estrategia.

Fase II: Métodos

El objetivo de esta segunda fase es utilizar la estimulación magnética transcraneal (TMS) para probar causalmente que las áreas identificadas en la Fase I son necesarias para implementar el cambio de estrategia. Basándonos en los resultados a nivel de grupo de la Fase I, identificaremos regiones de interés (ROI) clave que están más fuertemente asociadas con nuestras señales de sorpresa/error en la condición de ITI lento. En un nuevo conjunto de sesiones, los mismos participantes realizarán la tarea Flanker de nuevo. Antes de cada bloque, usaremos estimulación continua de ráfaga theta (cTBS) inhibitoria y fuera de línea para interrumpir temporalmente la función de esta ROI objetivo al final de cada ensayo. Una condición de TMS sham servirá como control.

Fase II: Hipótesis

La inhibición de las ROI objetivo interrumpirá la capacidad de usar información ensayo por ensayo para ajustar dinámicamente la estrategia. Esto tendrá efectos específicos y predecibles tanto en el comportamiento observable como en los parámetros latentes del DDM. (i) El TMS afectará principalmente el rendimiento en la condición de ITI lento. Predecimos que el TMS hará que el comportamiento de los participantes en la tarea lenta se parezca más a su comportamiento en la tarea rápida: serán más rápidos, más propensos a errores y su variabilidad de RT ensayo por ensayo disminuirá. (ii) El efecto primario del TMS será sobre los parámetros del DDM que su modelo ha vinculado al ajuste dinámico. Específicamente, el TMS disminuirá el efecto de los predictores de sorpresa/error en los parámetros del DDM.

Métodos

Parametrización

El modelo principal utilizado es un DDM diseñado para probar la hipótesis de que la estrategia inhibitoria de un participante es modulada dinámicamente por sus expectativas ensayo por ensayo, y que esta modulación depende a su vez del contexto temporal general (ITI corto vs. largo). La verosimilitud se estimó para cada ensayo t y participante s como:

$$RT_{st}, \text{Choice}_{st} \sim \text{Wiener}(\alpha_{st}, \delta_{st}, \tau_{st}, \beta_{st})$$

La expectativa dinámica del tipo de ensayo se definió como la expectativa ensayo por ensayo E para el sujeto s y el ensayo t , recursivamente de la siguiente manera:

$$E_{st} = \alpha_s \cdot O_{st} + (1 - \alpha_s) \cdot E_{s,t-1}$$

La tasa de aprendizaje específica del sujeto (α) se estimó como un parámetro libre no restringido y luego se pasó a una función logística para asegurar que esté entre 0 y 1:

$$f(\alpha) = \frac{1}{1 + e^{-x}}$$

Luego, los parámetros del DDM del ensayo t se modelan como una combinación lineal de las condiciones experimentales y las expectativas (error de predicción del modelo de media móvil exponencial) del ensayo previo $E_{s,t-1}$. Para la separación de límites definimos la combinación lineal como:

$$\alpha_{st} = \beta_0 + \beta_1 \cdot E_{s,t-1} + \beta_2 \cdot \text{ITI}_s + \beta_3 \cdot (E_{s,t-1} \cdot \text{ITI}_s)$$

Esto representa una política proactiva, que considera el conocimiento sobre la estructura general y la previsibilidad de la tarea. Tasa de deriva:

$$\delta_{st} = \gamma_0 + \gamma_1 \cdot S_{\text{RT},s,t-1} + \gamma_2 \cdot \text{ITI}_s + \gamma_3 \cdot \text{Congruencia}_{st}$$

Donde $S_{\text{RT},s,t-1}$ se deriva de una regresión lineal simple sobre los RT de los participantes y los residuos estandarizados. Esto refleja un ajuste reactivo de la eficiencia del procesamiento. Contrariamente a la separación de límites, esto sugiere un procesamiento más ascendente, que considera el rendimiento previo (en términos de RT) para modular la estrategia inhibitoria. Tiempo no decisional:

$$\tau_{st} = \delta_0 + \delta_1 \cdot \text{ITI}_s$$

Sesgo del punto de partida:

$$\beta_{st} = \zeta_0$$

Las estimaciones se computaron participante por participante, para tener en cuenta las sensibilidades individuales. Los dos últimos DDM están menos parametrizados ya que no tenemos una consideración explícita sobre cómo se ven afectados por las características de la tarea, la decisión específica de no incluir un coeficiente de ITI para el sesgo del punto de partida se debe a los resultados presentados anteriormente que no muestran interacción del ITI.

Bondad de Ajuste

Para determinar la bondad de ajuste del modelo, realizamos una comparación entre el modelo completo (mencionado anteriormente) y una versión restringida, que es solo los parámetros del DDM con un intercepto. Dado que las verosimilitudes del modelo se especifican por participante, primero usamos una prueba de razón de verosimilitud por participante. Primero se calcula el estadístico de desviación.

$$D = 2 \cdot (\text{NLL}_{\text{restringido}} - \text{NLL}_{\text{completo}})$$

Y obtuvimos los valores p de la razón como:

$$P_{\text{val}} = P(\chi^2(D, df = 9))$$

Dado que estos valores p son observaciones independientes, usamos la prueba de probabilidad combinada de Fisher para derivar el estadístico de comparación de modelos general. Primero se calcula el estadístico chi-cuadrado de Fisher, donde p son los valores p individuales y k es el número de valores p:

$$\chi_{2k}^2 = -2 \sum_{i=1}^k \ln(p_i)$$

Luego, el valor p general es:

$$P_{\text{final}} = P(\chi_{2k}^2 > \chi_{\text{Fisher}}^2)$$

Variabilidad de la Estrategia

La lógica aquí es que un modelo bien especificado mostrará un menor error de predicción en condiciones en que la selección de estrategia es más consistente, y un mayor error de predicción cuando la estrategia es menos consistente o depende de información previa inmediata (cambia ensayo por ensayo). Para hacer esto generamos una función de

predicción usando los parámetros DDM estimados por participante y la ejecutamos sobre los datos reales de los participantes, calculamos el error cuadrático medio por ensayo, las predicciones se hicieron usando `rwienr` que genera RT a partir de una distribución de Wiener:

$$\text{RSE} = \sqrt{(\text{rt} - \hat{\text{rt}})^2}$$

Finalmente, para determinar las diferencias en el error entre ITI, ajustamos un modelo lineal mixto:

$$\text{RSE}_{ij} = \beta_0 + \beta_1 \cdot \text{ITI}_{ij} + u_{0j} + \epsilon_{ij}$$

Donde RSE es el error cuadrático medio (para hacer los cálculos más estables usamos el log de RSE para el ajuste del modelo, sin embargo, los informes se hacen en la escala original), B0 es el intercepto fijo general, B1 es el efecto fijo de la tarea, u0j es el intercepto aleatorio para el participante j, que representa la desviación del sujeto del RSE promedio general, y eij es el error residual para esa observación.

Referencias

Eriksen, B. A., & Eriksen, C. W. (1974). Effects of noise letters upon the identification of a target letter in a nonsearch task. *Perception & Psychophysics*, 16(1), 143-149. <https://doi.org/10.3758/bf03203267>

Gold, J. I., & Shadlen, M. N. (2007). The Neural Basis of Decision Making. *Annual Review of Neuroscience*, 30(1), 535-574. <https://doi.org/10.1146/annurev.neuro.29.051605.113038>

Mansouri, F. A., Tanaka, K., & Buckley, M. J. (2009). Conflict-induced behavioural adjustment: A clue to the executive functions of the prefrontal cortex. *Nature Reviews Neuroscience*, 10(2), 141-152. <https://doi.org/10.1038/nrn2538>

Meyniel, F., Maheu, M., & Dehaene, S. (2016). Human Inferences about Sequences: A Minimal Transition Probability Model. *PLOS Computational Biology*, 12(12), e1005260. <https://doi.org/10.1371/journal.pcbi.1005260>

R Core Team. (2025). *R: A Language and Environment for Statistical Computing*. R Foundation for Statistical Computing. <https://www.R-project.org/>

Ratcliff, R. (1978). A theory of memory retrieval. *Psychological Review*, 85(2), 59-108. <https://doi.org/10.3758/0033-295x.85.2.59>

Wabersich, D., & Vandekerckhove, J. (2014). The RWiener package: An R package providing distribution functions for the Wiener diffusion model. *The R Journal*, 6(1), 49-56.

Figuras

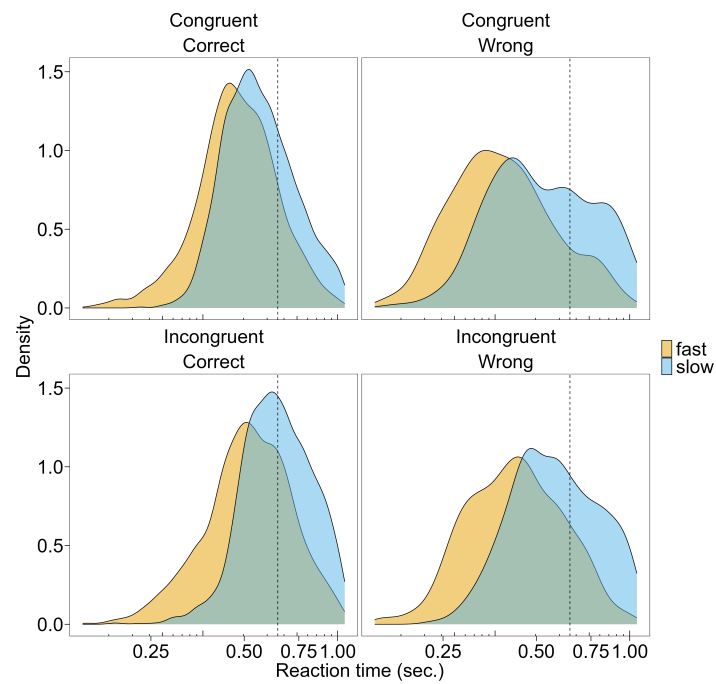


Figure 1: Estimación de densidad kernel para las condiciones congruente/incongruente en las condiciones de ITI rápido y lento. La línea vertical discontinua representa el tiempo de reacción medio general a través de las condiciones.




Figure 2: Efecto Flanker. Medias marginales estimadas por un modelo lineal mixto para los tiempos de reacción (ms.) en las condiciones "rápido" y "lento", en las condiciones "congruente" e "incongruente", incluyendo ensayos correctos e incorrectos. Nota: * = $p < 0.05$, los bigotes son intervalos de confianza del 95%.




Figure 3: Tasas de error. Estimaciones marginales de un modelo mixto generalizado de la probabilidad de una respuesta correcta en todas las condiciones. Notas: $*$ = $p < 0.05$, los bigotes son intervalos de confianza del 95%.




Figure 4: Efecto del RT del ensayo previo en la selecci3n de la estrategia actual. Tendencias marginales estimadas por un modelo lineal mixto para todas las condiciones, los bigotes son intervalos de confianza para las estimaciones por condici3n.

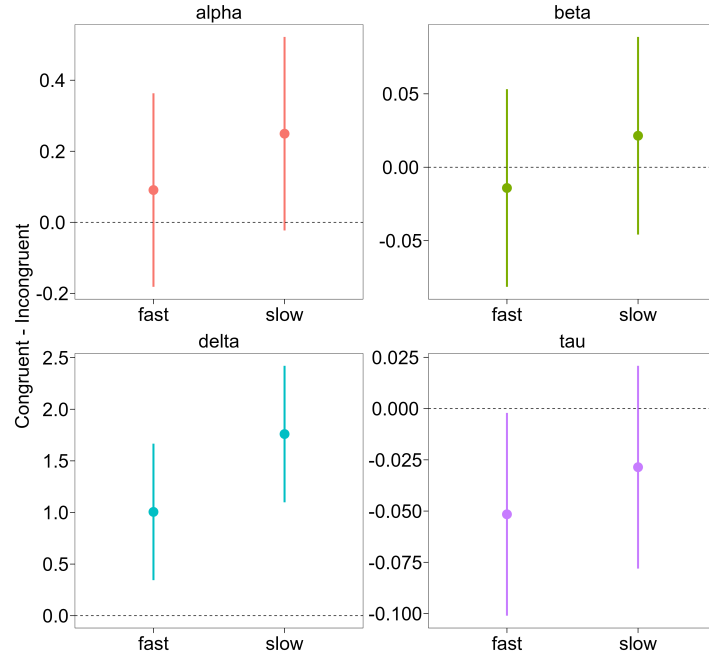


Figure 5: Estimaciones del modelo congruente versus incongruente para todos los parámetros DDM, los bigotes son intervalos de confianza del 95%.




Figure 6: Estimaciones bootstrapped para el modelo DDM completo, la etiqueta de la faceta indica los parámetros DDM, mientras que el eje x contiene los elementos de la combinación lineal. Los bigotes son IC del 95%.